# **Cloudera Migration**

- 1. <u>데이터 적재</u>
- 2. Cluster to Cluster 데이터 이관
- 3. Cluster to S3 데이터 이관
- 4. 비교

## 1. 데이터 적재

1. 데이터 선정 (Kaggle)

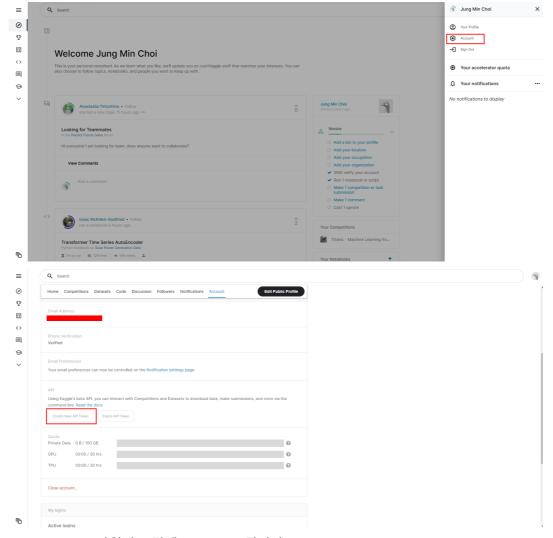
allposts.csv: 43.09 GB
 deletedposts.csv: 5 GB

3. chats 2021-04.csv: 11.17 GB

2. Kaggle 작업 환경 구성

#### 참고 자료

1. kaggle api key 생성



kaggle.json 파일이 로컬에 download 됩니다.

- 2. sftp로 kaggle.json 파일 server에 upload
- 3. library 설치 및 데이터 download

```
# sftp 로 kaggle.json 파일 ~/에 upload

mkdir -p ~/.kaggle # 유저의 홈디렉토리에 .kaggle 폴더 생성

cp kaggle.json ~/.kaggle/kaggle.json # 현재 폴더의 kaggle.json 파일을 복사

chmod 600 ~/.kaggle/kaggle.json # kaggle.json을 오너만 읽기, 쓰기 권한 할당

export PATH=$PATH:/home/ec2-user/.local/bin # kaggle 명령어를 실행어를 어디
서나 실행하기 위해 Path 설정

# 아래 명령어는 위에서 Kaggle Dataset API 복사 된 것을 붙이기 하세요

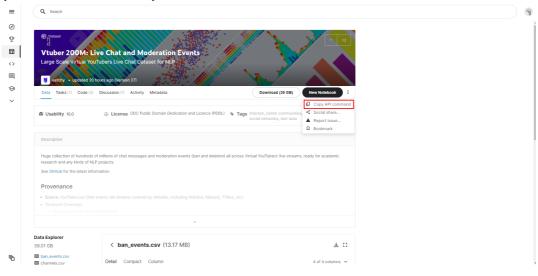
{KAGGLE API COMMAND} -p download_data # kaggle 명령어 실행해서 다운로드

mkdir -p datas # data_dir 폴더 생성

unzip download_data/{download_zip file} -d datas/{data dir}

rm -rf download_data # downlaod_dir 폴더 제거
```

#### {KAGGLE API COMMAND}:



#### 3. 데이터 적재

```
# hdfs 폴더 생성
sudo -u hdfs hadoop fs -mkdir {target_dir}

# hdfs 권한 변경
sudo -u hdfs hadoop fs -chmod 777 {target_dir}

# hdfs 파일 내역 확인
sudo -u hdfs hadoop fs -ls /

# hdfs put 명령어로 데이터 넣기 (40g 기준 약 15분 소모)
sudo -u hdfs hadoop fs -put {source_dir} {target_dir}

# hdfs file size 확인
sudo -u hdfs hadoop fs -du -h /
```

### 2. Cluster to Cluster 데이터 이관

```
# Node Storage 확인
sudo -u hdfs hadoop dfsadmin -report

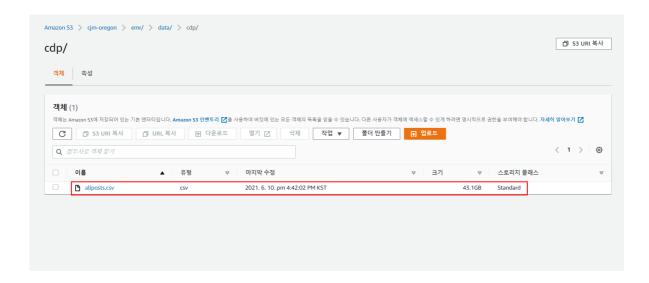
# 데이터 이관
sudo -u hdfs hadoop distcp -skipcrccheck -update {source_dir}
hdfs://{EMR_Master_Private_Ip}:8020{target_dir}
```

```
| Decompton | Deco
```

## 3. Cluster to S3 데이터 이관

40GB 기준 약 11분 소요

```
# CDP to S3 이관
sudo -u hdfs hadoop distcp -Dfs.s3a.access.key={ACCESS_KEY} -Dfs.s3a.secret.key=
{SECRET_KEY} {source_dir} s3a://{S3_Bucket}/{path}
```



# S3 to EMR 이관 s3-dist-cp --src=s3a://{S3\_Bucket}/{path} --dest=hdfs://{target\_dir}

```
Lamched reduce taskes)

Lamched reduce taskes)

Italia is spent by all maps in occupied slots (ms)=200324

Total it is spent by all maps in occupied slots (ms)=200324

Total it is spent by all maps in occupied slots (ms)=200326

Total transport by all maps in occupied slots (ms)=200326

Total transport by all maps in occupied slots (ms)=200326

Total vore=milliseconds taken by all reduce taskes/0000

Total vore=milliseconds taken by all reduce taskes/00000

Total vore=milliseconds taken by all reduce taskes/000000

Total vore=milliseconds taken by all
```

## 4. 비교

비교 방법: S3 의 파일(약 40GB) distcp로 이동

1. 설정 값

유형	Cloudera	EMR
Туре	t2.large	m5.xlarge
vCPU	2	4
메모리	8	16
스토리지	EBS 전용	EBS 전용
명령어	sudo -u hdfs hadoop distcp -Dfs.s3a.access.key={Access_Key} -Dfs.s3a.secret.key={Secret_Key} s3a://{Bucket_Name}/{Path} {Target_Dir}	s3-dist-cp src=s3a://{Bucket_Name}/{Path} dest=hdfs://{Target_Dir}
수행시간 (ms)	908182	907408

#### 2. 결과

약 15분 정도로 비슷한 결과값 도출

```
21/80/15 02:36:17 HMC maproduce.Job: Job job. 1623722773859_0001 completed successfully
File: Spatial policy stream of the process of the pro
```